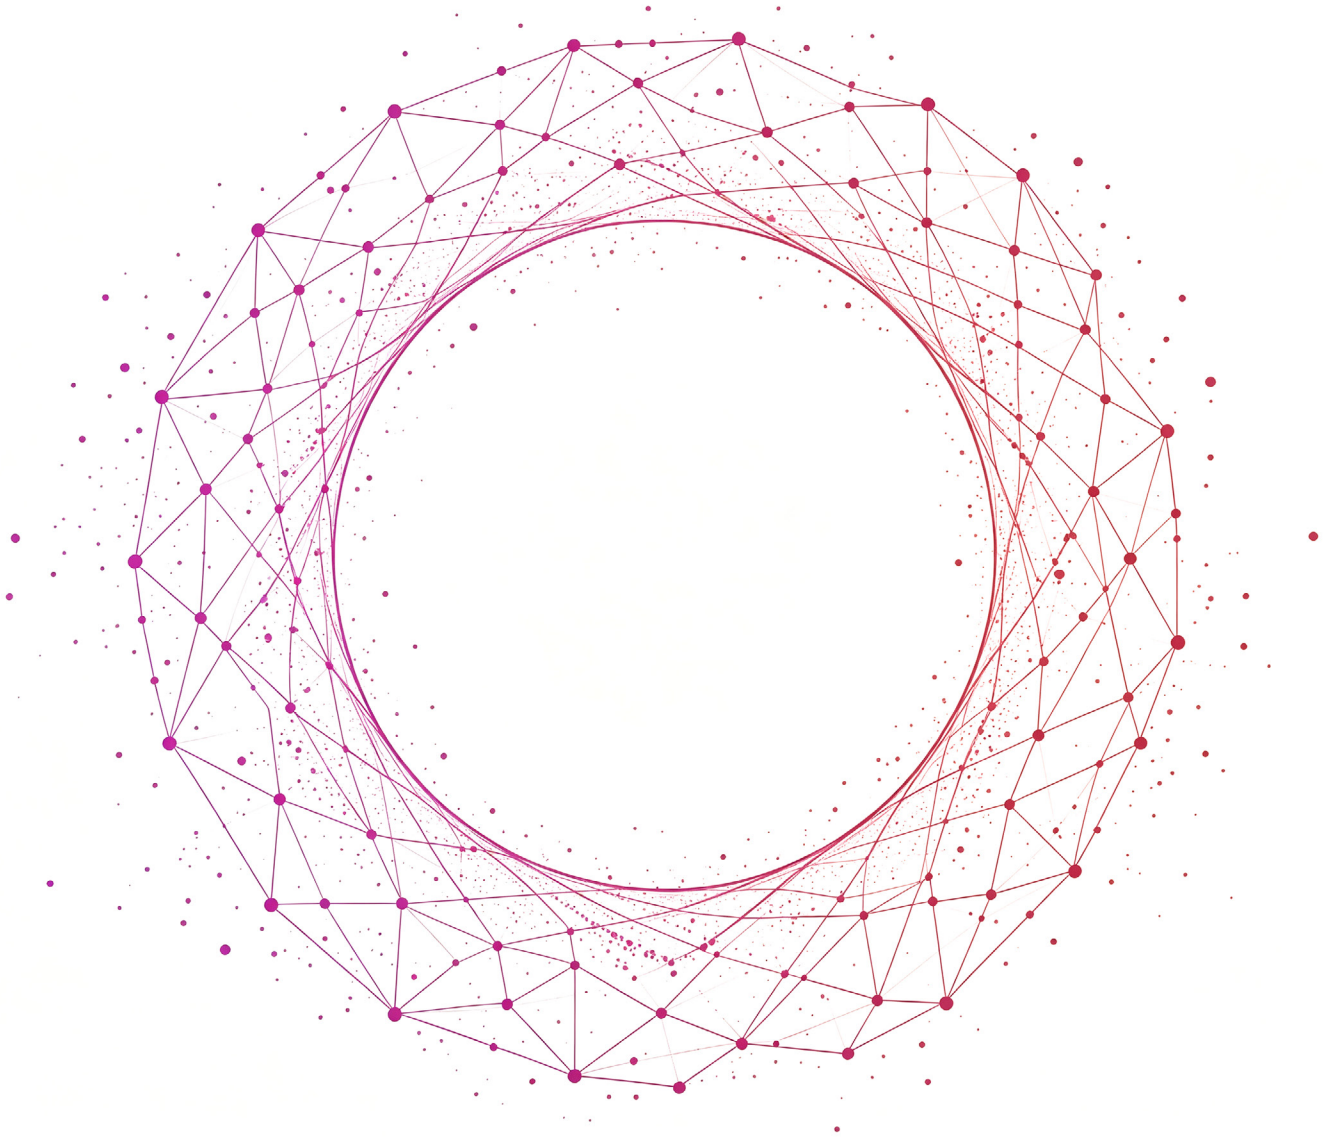
国际先进技术应用推进中心（深圳）
CENTER FOR APPLICATION PROMOTION OF
INTERNATIONAL ADVANCED TECHNOLOGY (SHENZHEN)

# 当 Scaling Law 遇见物理定律，世界模型与大模型的逻辑差异

2026 年 9 月



# 目 录


01 世界模型热潮 ..... 01

1.1 百家争鸣的世界模型 ..... 02

1.2 向产业上游发掘的热点 ..... 05

1.3 热潮下的大模型经验投射 ..... 06

02 从生成式模型到物理世界模型的概念谱系 ..... 07

2.1 从生成式模型开始的技术延伸 ..... 08

2.2 世界模型的内涵与发展 ..... 10

03 世界模型的技术演进与应用 ..... 13

3.1 从视觉生成到隐空间表征 ..... 14

3.2 从几何一致性到动力学一致性 ..... 15

3.3 从状态预测到因果决策 ..... 17

04 世界模型与大模型发展对比分析 ..... 20

4.1 技术范式差异 ..... 21

4.2 工程差异：模型从大到小的逆向挑战 ..... 22

4.3 价值兑现差异：世界模型价值依赖下游载体爆发 ..... 23

05 结论与趋势分析 ..... 24

5.1 世界模型正在从“生成式 Scaling”到“JEPA 式结构创新” ..... 25

5.2 世界模型将形成混合架构、功能分层的复杂系统 ..... 25

5.3 物理世界的现实摩擦力将延缓产业应用节奏 ..... 26

5.4 下游载体进入商业化与纵向整合趋势 ..... 26

5.5 从百家争鸣到聚焦，收敛周期将显著长于大模型 ..... 27

# 表目录

表 1 部分国内世界模型相关企业梳理.....04

表 2 世界模型三种功能角色.....11

# 图目录

图 1 具身智能赛道热点变化.....05

图 2 视觉生成模型技术发展历程.....09

图 3 世界动作模型及相关概念对比.....18

图 4 世界动作模型技术路线示意.....19

# 01 世界模型热潮

> 具身智能的终极目标，是让机器在开放、非结构化的物理环境中实现可靠的感知、决策与执行，然而当前主流的 VLA 模型范式，能力边界正在逐渐显露。大语言模型的成功建立在互联网数十万亿 Token 的文本语料之上，而具身智能领域至今没有一个可比规模的真实物理交互数据集。同时，物理数据的采集成本极高，仿真数据的迁移鸿沟仍然是开放问题。正是在这一背景下，世界模型被推向前台。

## 1.1 百家争鸣的世界模型

世界模型的核心思想是让模型学习物理世界的内部表征与演化规律，从而能够在模型内预测未来状态、评估动作后果、生成训练数据。2018 年，David Ha 和 Jürgen Schmidhuber 发表论文《World Models》，提出了一种基于深度学习的框架，通过构建“世界模型”来模拟环境动态，从而提升强化学习（RL）的效率和泛化能力，也为人工智能发展提供了一种新思路。2024 年视频生成模型取得突破性进展后，产业界开始认真对待将其作为具身智能核心基础设施的可能性。

当前，产业界对“世界模型”一词的使用极为宽泛，缺乏共识。与“世界模型”并行出现的还包括“空间智能”“物理 AI”“具身世界模型等概念标签。李飞飞创办的 World Labs 将空间智能定义为理解和操作 3D 世界的能力”，英伟达则使用Physical AI”一词描述其仿真与机器人平台，而学术论文中“World Model”一词则更多指向特定任务的状态预测器。这些概念之间存在交叉，但其技术内涵、覆盖范围与评价标准并无统一界定。

概念的泛化直接投射在技术路线的分化上。当前国内涉足世界模型方向的团队，关键技术至少包括隐空间表征、视频生成、3D 重建与几何一致性、物理引擎嵌入以及因果推断等，可谓百家争鸣。与关键技术分化相伴生的，是创业团队的密集涌现。据不完全统计，除具有模型 - 本体闭环能力的头部具身智能企业外，当前国内明确以世界模型为技术标签的初创企业已超过二十家，大致可归为以下三种类型：

（1）具身大脑类企业

具身智能大脑类企业主要研发感知、预测与控制的算法栈，世界模型在其中并非独立产品，更多是嵌入具身大脑结构中的预测功能模块，以此提升长序列任务的成功率。

（2）多模态生成与物理仿真企业

多模态生成类企业大多以视频生成、3D 资产生成等方式，在物理一致性方面与世界模型产生关联，物理仿真类企业主要提供模拟器和数据，作为中间环节参与世界模型，但目前两者都并非具身智能可直接调用的物理状态预测器，更多是参与具身模型训练过程中的一环。

（3）世界模型前沿学者创业

世界模型领域前沿学者创业成为当前热点，创始人通常拥有国际顶尖高校或 AI 实验室的学术背景，直接以通用世界模型为核心命题，多偏向第一性原理讲述不同技术逻辑，企业落地方向也各有不同。

| 类别 | 企业名称 | 成立时间 | 融资进展 | 模型进展及特征 |
|---|---|---|---|---|
| 具身大脑企业 | 星动纪元 | 2023 年 | B+ 轮 | 2025 年 10 月，星动纪元创始人陈建宇与斯坦福大学 Chelsea Finn（PI 联合创始人）团队研发了 Ctrl-World 可控生成世界模型 |
| | 中科第五纪 | 2024 年 | A 轮 | 自研 BridgeV2W 具身世界模型，2026 年 4 月公司新一代世界模型 FlowWAM 登顶 WorldArena 全球榜单总分榜 |
| | 跨维智能 | 2021 年 | A+ 轮 | 2026 年 5 月，自研的通用具身世界模型 DSCFuncWorld，在 WorldArena Track 2（Data Engine）赛道斩获全球第一 |
| | 星源智 | 2025 年 | Pre-A 轮 | 团队在 2024 年提出了类似 JEPA 的技术路线，侧重端侧部署，已成为英伟达 JetsonThor 全球最大出货商 |
| | 眸深智能 | 2025 年 | Pre-A 轮 | 2026 年 6 月发布的 STI-WM 时空一体世界动作模型实现了 3D 感知、物理推理与动作生成的原生融合 |
| | 具脑磐石 | 2025 年 | 天使轮 | 由前华为具身智能大脑核心负责人朱森华创立，构建以类脑主动推理为核心的认知世界模型 |
| 多模态生成和物理仿真 | 极佳视界 | 2023 年 | B2 轮 | GigaWorld-1 在 WorldArena 中登顶全球榜首，成为首个综合得分突破 60 分的具身世界模型 |
| | 生数科技 | 2023 年 | B 轮 | 2026 年 4 月正式发布的商用级通用世界行动模型 MotuBrain，基于 UniDiffuser 统一建模框架，将视频生成、动作预测、语言理解等能力深度融合 |
| | VideoRebirth | 2024 年 | Pre-A 轮 | Video Rebirth 以视频生成为切入点，通过 Bach 引擎和 DDIT/PNA 架构构建工业级视频原生世界模型 |
| | Sand.ai | 2025 年 | A++ 轮 | 坚持自回归架构，其核心产品 Magi-1 是全球首个自回归视频生成大模型，通过逐帧预测视频块序列来生成内容 |
| | 智象未来 | 2023 年 | B+ 轮 | 2026 年 4 月发布基于 UiT 架构的 HiDream-O1-Image 图像大模型。与诺亦腾机器人战略合作，采用“真实动捕数据 + 生成式视频数据”融合范式 |
| | VAST | 2022 年 | A+ 轮 | 发布 Project Eden 的世界模型项目，确立状态推演与视觉渲染原生解耦的技术路线，利用 Tripo 系列高效生成的 3D 资产，实现世界的动态推演与交互 |
| | 云悟智能（Feeling AI） | 2024 年 | 天使轮 | 自研动力学世界模型与 IKGT 算法，侧重动态交互，在 3D 原生结构下，可以实现对人类运动交互的生成与状态预测 |
| | 深度机智 | 2025 年 | 天使轮 | 2026 年 3 月发布具身通用智能基座模型 PhysBrain 1.0 和世界模型 Z-WM，5 月 Z-WM 模型在 WorldArena Track 2 夺冠 |
| | 光轮智能 | 2023 年 | A++ 轮 | 全球领先的仿真合成数据供应商，其自身不直接研发世界模型算法，通过提供高质量训练数据、可靠评测工具及参与构建全球仿真标准，成为世界模型的数据引擎与评测基座 |
| | 松应科技 | 2021 年 | Pre-A+ 轮 | 定位为仿真平台提供商，核心产品 ORCA 物理 AI 仿真系统，帮助客户在虚拟环境中进行机器人训练、测试和数据生成 |

| 类别 | 企业名称 | 成立时间 | 融资进展 | 模型进展及特征 |
|---|---|---|---|---|
| 世界模型前沿学者创业 | 苏度科技 | 2025 年 | Pre-A 轮 | 2026 年 4 月发布 Sudo R1 机器人系统，采用 3D 世界模型与强化学习一体化架构，通过仿真数据训练，无需依赖真机数据即可实现关键任务近 100% 的 Zero-shot 成功率 |
| | 视启未来 | 2025 年 | 天使轮 | 隐空间世界模型路线，拥有 EgoTwin 数据引擎和 3D 感知模型矩阵，优势在于将深厚的物体级视觉理解能力与隐空间表征学习深度融合 |
| | 流形空间 | 2025 年 | A 轮 | 强调对物理世界的确定性理解，2026 年 4 月发布 WorldScape 0.2，引入 MoE 架构，在 WorldScore 和 WorldArena 榜单上夺冠 |
| | 逆矩阵科技 | 2026 年 | 天使轮 | 强化学习驱动物理因果理解的技术路线，不将物理定律显式编码进模型，而是通过物理可验证的奖励信号，引导模型在隐空间中自然涌现出对物理规律的理解 |
| | 将闲科技（LiberAI） | 2025 年 | 天使轮 | 核心创新在于模态对齐与归纳偏置，将视频模态与物理模态在因果层面进行对齐，将物理规律作为人类先验知识注入模型，确保模型生成的预测符合物理常识 |
| | 魔芯科技 | 2021 年 | Pre-A+ 轮 | 纯数据驱动的隐式空间建模路径，模型直接在隐空间中学习 4D（3D 空间 + 时间）的 Token 表示，通过大规模前馈神经网络进行端到端训练。2025 年 12 月发布交互式世界模型 KOKONI-World |
| | 影溯智能（InSpatio） | 2025 年 | A 轮 | 显式 3D/4D 空间重建路线，提出状态锚定建模范式和轻量化架构，2026 年 3 月发布实时世界模型 inspatio-world，通过几何约束与重建算法，从普通单目视频中抽取空间知识，将其转化为带体积、位置、关系的三维表征，进而构建可探索、可交互的 4D 动态世界 |
| | 自然意志 | 2026 年 | 天使轮 | 世界模型 + 强化学习路线，强调可解释性与数据效率 |
| | 原识之智 | 2026 年 | 天使轮 | 以因果推理为核心，为具身智能体提供物理世界的因果理解能力 |
| | 章鱼动力 | 2026 年 | 天使轮 | VFT-WFM 更强调多模态物理信号的统一建模与实时操作反馈，直接服务于具身智能的“推理 - 执行”闭环，可视为从自动驾驶端到端架构的迁移与深化 |
| | 忆生科技 | 2023 年 | A 轮 | 强调物理规律的可解释性建模与跨场景知识复用，以 MCR 白盒理论为基石，通过自主数据生成、白盒模型优化、具身原生融合三大模块协同，并依托 I-CTRL 闭环学习机制实现自主进化 |
| | 拓元智慧（Xera AI） | 2021 年 | A 轮 | 以原生世界动作模型 VWA 为核心，强调物理与动作的联合建模、原生三维几何表征以及端侧实时部署，其模型 EonWorld 在 WorldScore、WorldArena 上多次登顶 |

（数据统计截至 2026 年 7 月）

**表 1　部分国内世界模型相关企业梳理**

## 1.2 向产业上游发掘的热点

世界模型成为当前的新热点,并非一个突然降临的风口,而是具身智能产业链上资本持续向更深、更上游挖掘的自然延伸。回顾过去三年的融资流向，具身智能产业持续吸引着资本的密集布局，可以清晰地辨识出一条资金从下游硬件向中游算法、再向上游数据与模型能力层逐级迁移的轮动轨迹。

2023 年具身智能进入产业视野之初，第一落点是下游的机器人本体企业。人形机器人被视为承载具身智能的终极硬件形态，其产业叙事直接对标智能手机与新能源汽车的早期阶段，这一阶段的逻辑可以概括为：在智能能力尚未成熟之前，先建立可量产、可部署的本体平台。

当本体企业的数量迅速膨胀、头部格局初现雏形后，一个更务实的价值链问题出现：本体企业的供应链瓶颈在哪里？哪个环节价值最高？行业逻辑快速变化，与其押注某一家本体企业胜出，不如押注所有本体企业都需要的那个共同瓶颈。

2024 年中开始，伴随国内外科研进展，让市场看到了“通用机器人算法”的曙光，当年自动驾驶领域的“全栈算法提供商”的叙事逻辑重新出现。模型算法差异的逻辑很快就因为 VLA 模型能力的边际效益减少而变化，物理交互数据的极度稀缺，解决数据瓶颈成为具身智能赛道最新的投资锚点。

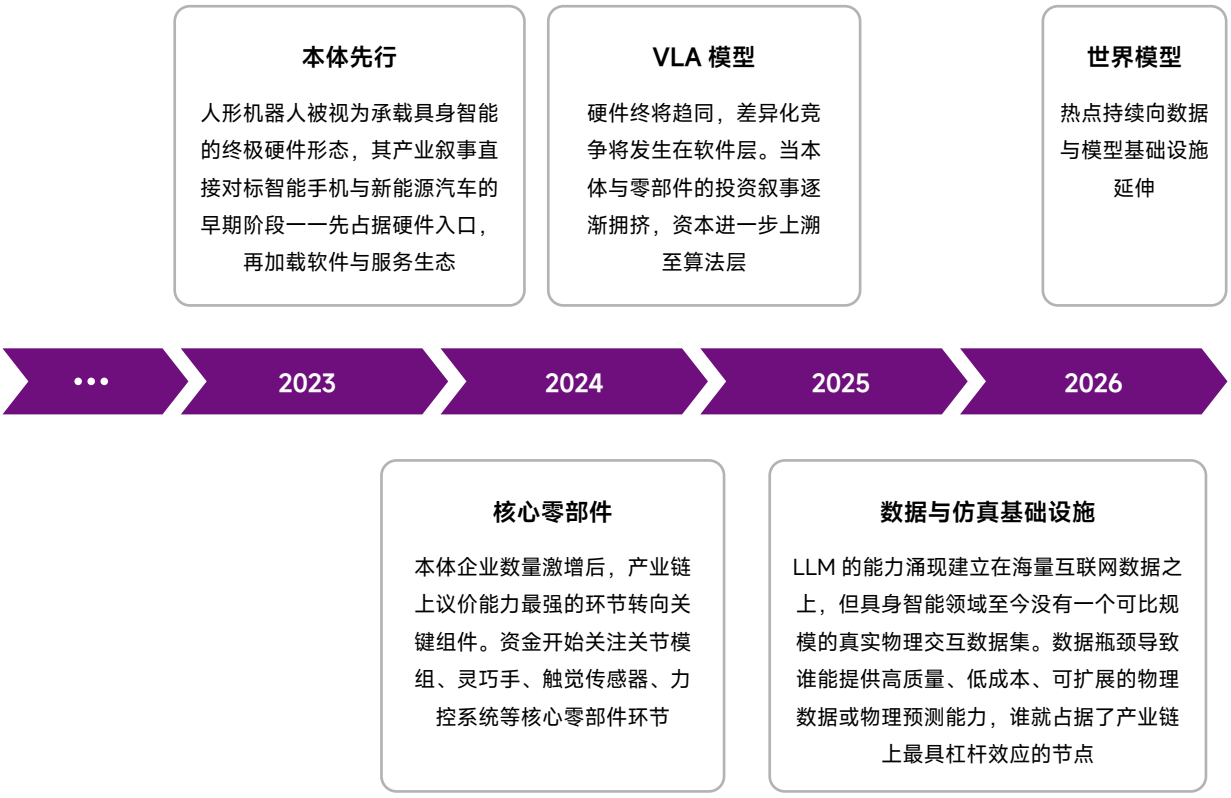



**图 1 具身智能赛道热点变化**

2025 年至今，数据路线不断创新，从 UMI、ego-centric 再到世界模型生成，然而，不断地向上游挖掘在带来新机会的同时，也隐含着不容忽视的结构性代价。

其一，估值溢价层层递进。每一次产业链上的热点迁移，都伴随着新一轮的估值重构。下游本体企业的估值尚未被营收充分消化，上游零部件企业的估值已先行抬升；零部件企业的商业化尚未大规模铺开，算法层企业的估值又再上一个台阶；如今，世界模型企业作为“基础设施的基础设施”，其估值已在部分案例中超过下游机器人本体企业同轮次的水平。溢价是基于“更上游意味着更高壁垒、更强定价权”的逻辑假设，但这一假设的前提是上游能力的价值终将被下游载体的大规模部署所兑现。

其二，价值兑现的链条和周期进一步拉长。具身本体企业的价值兑现路径相对直接：出货量 × 单价。一家核心零部件企业的兑现路径同样清晰：出货量 × 单件毛利。但一家世界模型企业的价值兑现，须经历至少三个传导环节：世界模型本身的技术成熟—下游具身载体的大规模部署—载体在具体场景中产生的经济价值。其中的每一环都充满不确定性，链条越长，预期与现实之间的偏差就越大，产业成熟所需的时间也越难以预估。

其三，产业成熟度与资本期待之间的落差扩大。资金越是向上游延伸，所触及的环节在技术成熟度和商业确定性上就越低。当前的世界模型创业项目，绝大多数仍处于技术验证阶段，尚难以实现在真实机器人任务中产生可量化的价值贡献。

在此背景下，一个更加现实的问题呈现眼前，当行业热点轮动，所有参与者是否对技术里程碑的判断、回报周期的预期同步完成了适配性的更新？

本文认为，当前产业和资本对世界模型的预期，带有大模型发展经验的惯性，一定程度上忽略了这一复杂工程系统的庞大资源投入，现实世界的摩擦成本也将持续拖慢模型应用落地的速度，而真正的行业繁荣必然需要经历资源整合和市场集中的危机洗礼。

## 1.3 热潮下的大模型经验投射

具身智能领域一直在追寻自己的“GPT-3.5 时刻”，尤其在 VLA 模型能力增长放缓、数据瓶颈明显的当下，世界模型被视为最具潜力的突破方向之一。其核心构想是，在机器人内部构建一个能够动态预测行为因果的内生世界，使模型在行动之前就能“想象”后果，从而突破真实交互数据的约束。

过去五年大模型的发展，逐渐形成了一套默认的认知框架。参数规模的持续扩大将触发能力的非线性涌现，统一的 Transformer 架构可以通用地建模复杂分布，训练后云端集中部署的规模化推理能够支撑商业闭环。世界模型的产业叙事，在很大程度上延续了这套框架，将其从数字空间平移至物理空间。

世界模型同样承载了“通用大模型”的期待，形成一个具备能力涌现、实现通用功能的物理世界基座模型。但物理世界的状态空间与语言符号空间存在本质差异，现实中存在着无法消弭的“物理摩擦力”。比如起步更早的自动驾驶，目前尚未实现单一场景下的完全通用，一个更大规模的世界模型是否必然带来更强的物理预测能力，既无实验证据支撑，也缺乏理论上的必然性推导。

大模型的成功为世界模型提供了坚实的技术起点和资本信心，但它同时带来了一系列被默认接受却未经审视的预期。当行业热点轮动，技术成熟度的判断、商业进展、回报周期等因素变化，将直接影响赛道资源分配的效率与产业预期的管理。

# 02 从生成式模型到物理世界模型的概念谱系

在正式讨论世界模型的技术演进与产业逻辑前，有必要先厘清当前多种混淆的概念边界。当前产业界对发展目标、学术名词、技术范式等术语进行了宽泛使用，导致在语义交流中存在较大偏差，无法直接体现技术和发展路径的区别。

本章试图在生成式模型与物理世界模型之间建立一条清晰的概念谱系，并在此基础上界定世界模型的核心内涵、功能角色及其在具身智能中的产业形态。

## 2.1 从生成式模型开始的技术延伸

**（1）大语言模型：符号空间中的统计自洽**

在计算语言学中，语言模型被严格定义为“对词序列概率分布进行建模的计算模型”（Jurafsky & Martin, 2023），即给定一个符号序列的前缀，预测下一个符号的条件概率。

以 GPT-4、Claude、Llama 等为代表的大语言模型，利用 Transformer 架构，将这一传统定义推向了极致。Transformer 的核心是自注意力机制，允许序列中的每一个位置直接关注上下文的所有其他位置，从而捕获长距离的语义依赖。在训练过程中，文本经过分词器被切分为 Token 序列，每个 Token 被映射为高维向量空间中的嵌入向量，并叠加位置编码以保留序列顺序信息。随后，多层 Transformer 块对这些向量表示进行迭代变换，最终在输出层产生下一个 Token 的概率分布。

当前主流的大语言模型大多采用 Decoder-only 架构，以自回归方式逐 Token 生成文本。这一架构的重要前提是，语言可以被线性化为离散符号的序列，语义在向量空间中被几何关系所近似。然而，语义向量空间的维度是有限的，通常为数百至数千维，其承载的语义结构完全由训练语料的统计分布所决定。

当模型生成文本时，它在做的本质上是在已有语料的概率分布中进行采样和组合。这是一种统计自洽，由人类主观感受对其正确性进行判断，比如流畅度、连贯性、逻辑性等。因此，即使在几乎没有物理世界标注数据的情况下，大语言模型也能通过海量互联网文本语料达到人类语言组织水平。

**（2）视觉生成模型：像素空间中的视觉逼真**

视觉生成模型在技术范式上与语言模型一脉相承，但其发展路径更为曲折。从早期的生成对抗网络（GAN，Goodfellow et al.，2014）和变分自编码器（VAE，Kingma & Welling，2014），到后来的扩散模型（Diffusion Model），再到与 Transformer 架构实现深度融合的 DiT 架构，视觉生成逐渐实现了视觉生成从二维单帧走向时空联合建模的质变。

自然图像和视频没有离散的符号单元，“视觉 Token 化”过程，是视觉生成模型从像素空间进入特征空间的关键一步。2024 年，Sora 开创性地将视频数据压缩为低维隐空间表征，再分割为时空块（Spacetime Patches），使用 Transformer 在这些视觉 Token 上执行去噪任务。为了将 Transformer 引入视觉生成，研究者将图像划分为固定大小的块，将每个块映射为高维隐空间中的向量，从而人为构建出一个“视觉词表”。在这个隐空间中，模型遵循着与语言模型极为相似的自监督逻辑，给定被噪声破坏的视觉 Token 序列，预测原始干净的 Token。

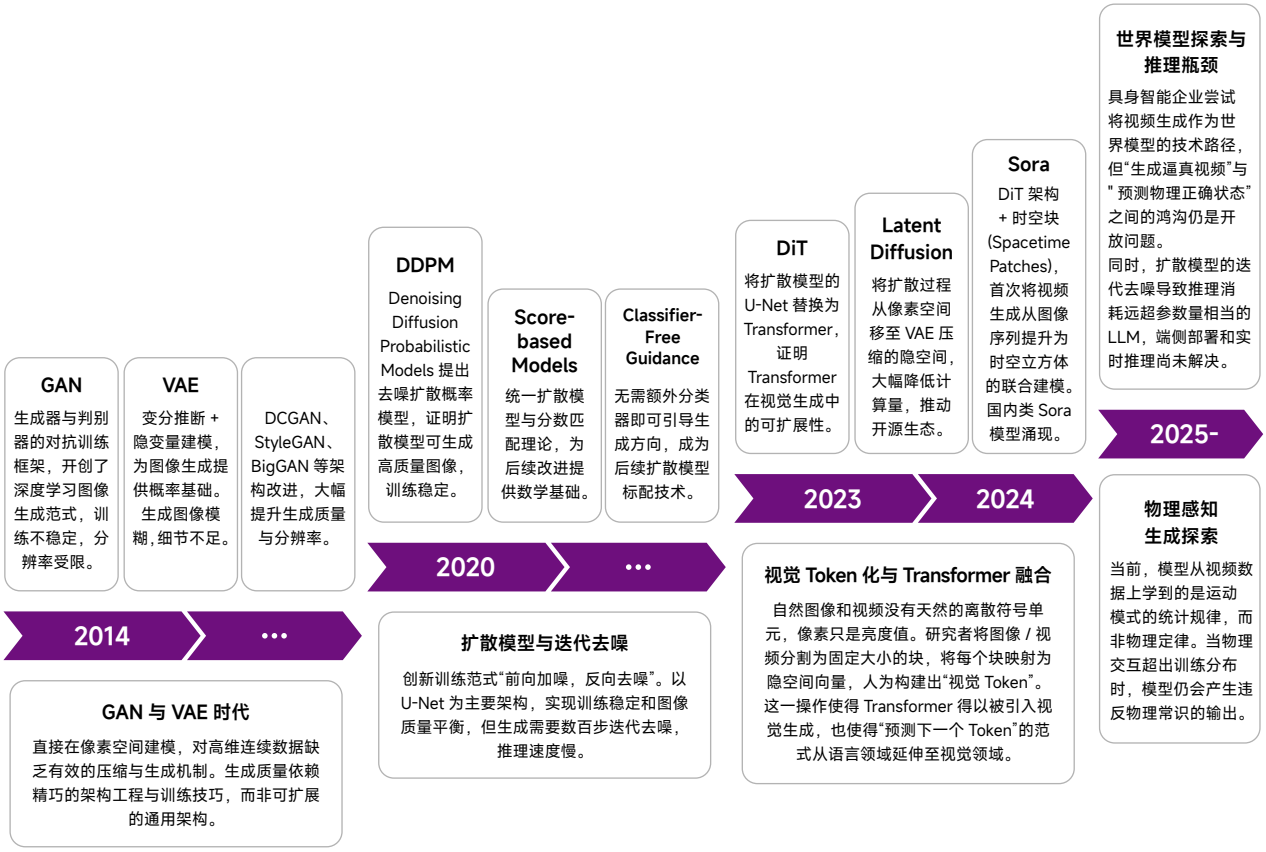



**图 2　视觉生成模型技术发展历程**

视觉 Token 化打通了 Transformer 在视觉领域的应用通道，但只实现了视觉真实感。早期模型在生成动态场景时，空间关系容易错乱，物体会凭空消失、刚性体会发生非物理的扭曲、遮挡关系在帧间频繁跳变。以 DiT 和 Sora 为代表的视频生成模型，通过时空 Patch 与大规模注意力机制，在很大程度上克服了这些显性缺陷。模型学会了物体持久性（object permanence），呈现出的空间变化更符合人类视觉效果。

因此，视觉生成模型的定位仍偏向像素空间中的概率模型，其真值由训练视频数据的像素分布定义，其“正确性”是统计意义上的逼真。

### （3）从“视觉逼真”到“物理正确”的关键转折

视频生成模型在数字空间中取得了巨大的进展，让人产生了一个直觉上的推论：如果模型能够生成一段符合视觉预期的视频，就意味着模型内在地“理解”了视频中物体运动与交互的规律。

然而，视觉逼真与物理正确之间，存在一条不易察觉却至关重要的鸿沟。这条鸿沟可以区分为两个递进层次：显性空间关系的几何合理性与隐性物理参数的动力学正确性。

生成式模型主要运作空间是数字化的符号或像素，其训练范式是数据驱动的自监督学习。视频生成模型的训练目标是像素分布的重建误差最小化，通过对数据分布的学习能够呈现出符合人类视觉的空间关系，另一角度看，模型无需在任何一帧画面中，估计或维持隐性物理参数。

因此，当 AI 从数字空间走向物理空间，生成式模型的能力上限逐渐显露。在维度较低的交互活动中，生成式模型能够发挥有效的预测作用，一旦进入高维度的操作交互，许多策略将在物理检验的严格限制下失效。这一需求将研究者的目光推向“状态转移在物理上可验证”的方向。

## 2.2 世界模型的内涵与发展

**（1）物理世界模型：满足物理一致性的状态预测**

“世界模型”已成为产业热词，其概念边界在当前语境下高度泛化。视频生成模型、物理仿真平台、甚至具备记忆与预测功能的通用神经网络，都可在不同叙事中被冠以“世界模型”之名。这种概念的膨胀使得技术讨论容易失去共同的评价基准。

因此，本文在此对讨论对象进行严格限定，下文所称的“世界模型”，特指狭义上的物理世界模型（Physical World Model），其核心意义是承担着主体 - 环境动态建模的预测功能，即在物理状态空间中运作的预测器，满足物理一致性硬约束。

物理一致性在学术上源自对动力学模型的研究。Sutton（1990）提出的 Dyna 架构，使智能体在内部世界模型中模拟真实环境的交互以加速学习。Hafner（2019）等在 PlaNet 首次实现了从像素级观测中端到端学习隐空间动力学模型，并直接在隐空间中执行模型预测控制。并在后续 DreamerV3 的研究工作中进一步将这一范式的规模扩大，证明了在世界模型隐空间想象中训练的智能体可完成多种复杂的连续控制任务。LeCun（2022）在《A Path Towards Autonomous Machine Intelligence》中将世界模型提升为自主智能系统架构的核心模块，明确要求其预测结果必须经受物理交互验证。动力学模型方向的研究，其技术根基是基于模型的强化学习，强调学习“动作如何改变世界状态”的转移规律，而非生成视觉上逼真的画面。

当前，在具身智能的产业需求推动下，动力学模型与生成式模型两大路径正在发生交汇与融合，但都共同指向一个核心定义，世界模型目标在智能体内部构建一个对物理环境演化规律的模拟器，使其能够在采取行动之前预测行为后果，追求物理状态的正确性。

**（2）物理一致性层级与功能分化**

2024 至 2025 年间，随着具身智能产业化快速发展，出现了多种将世界模型融入机器人控制的具体范式。世界模型需要为下游策略生成训练数据、搭建可交互的虚拟环境、探索自主决策并输出动作。

不同的应用需求决定了世界模型在实践中逐渐分化为三种功能角色。这三种角色并非并列的技术分类，而是物理一致性要求逐级提升的三个实践阶段。

| 类型 | 输入 | 输出 | 任务问题 | 典型代表 |
| --- | --- | --- | --- | --- |
| 渲染器 / 合成器<br>Renderer | 动作 / 指令 /<br>视角 / 状态 | 观测（像素、视频） | 世界看起来什么样 | Sora、Genie 3、<br>文生视频 |
| 模拟器<br>Simulator | 动作 + 当前状态 | 下一状态<br>（几何 / 物理 / 动力学） | 世界会变成什么样 | 学出来的动力学模型、<br>物理引擎 |
| 规划器<br>Planner | 观测 + 任务目标 | 动作（序列） | 智能体下一步该做什么 | VLA 模型 |

**表 2 世界模型三种功能角色**

合成器的定位是数据引擎，回答的问题是："给定一个动作或任务指令，世界看起来会是什么样？"在这一角色下，世界模型以动作或任务描述为条件，生成对应的视觉观测序列，为下游策略训练提供虚拟数据。合成器的价值在于突破真实交互数据的稀缺瓶颈，其对物理一致性的要求相对宽松，几何关系基本合理即可。

模拟器是基于模型的强化学习传统所定义的经典角色，搭建虚拟交互环境，推演动作后果，从中提取奖励信号或评估候选动作。它回答的问题是："如果执行某个动作，世界会变成什么样？"。模拟器必须保证状态转移的物理合理性，需要在力学上可验证，充当策略训练的内部评判。

规划器代表了技术演进前沿，核心定位是直接输出决策。它回答的问题是："为达成目标，下一步该做什么？"在此范式下，世界模型与动作生成深度融合，根据对未来状态的推演直接产生动作序列。规划器代表了世界模型从"辅助系统"向"决策系统"的演进方向，也是对物理一致性需求的进一步提升，如何实现因果一致成为核心问题。

**（3）世界模型的应用发展**

世界模型成为具身智能领域的关注焦点，源于具身智能产业化进程面临的三个应用需求：

第一，极度稀缺真实交互数据。具身智能的真实交互数据采集成本极高，而策略训练却需要海量多样化的示范样本。这一矛盾将世界模型推向了合成器角色，希望模型能生成虚拟交互数据，以替代昂贵的真机采集。

第二，依赖高质量的仿真环境。基于强化学习的策略训练需要虚拟环境，训练得到的行为部署到真实世界时，需要保持力学上的正确。此外，世界模型的模拟器功能被寄予厚望，希望其能在不依赖真机的前提下完成迭代优化与验证评估。

第三，追求面对复杂环境的自主决策能力。在复杂操作场景中，机器人需要理解物理原理和规则，甚至形成类似"直觉"的快速反应行为。这将需要世界模型推演未来状态，并基于物理正确的推演直接输出动作决策。

因此，世界模型需要为下游策略生成训练数据、搭建可交互的虚拟环境、探索自主决策并输出动作，不同的应用需求决定了世界模型扮演不同的角色，为满足这些角色的能力要求，世界模型的技术沿着不同方向演进。

从模仿学习到自主探索，世界模型不仅要预测下一时刻状态，还必须保证状态转移序列在动力学上的合理性，进而能为各种学习框架提供支撑。世界模型大致需要具备以下四种支持能力：

①模仿学习：通过生成或筛选高质量的演示轨迹，让智能体像学徒一样观察并模仿专家的行为，从而学会完成任务。

②强化学习：允许智能体在世界模型内部模拟执行动作并观察结果，然后基于这些虚拟经验来优化策略，从而减少真实环境中的试错成本。

③奖励建模：利用世界模型对动力学或未来结果的预测能力，自动生成奖励信号，减少人工设计奖励函数的麻烦。

④策略评估：将世界模型当作一个数据驱动的模拟器，在其中进行虚拟推演与测试，从而在不实际部署的情况下评估策略的性能，提前发现潜在问题。

目前，世界模型在具身智能策略学习中主要承担两种功能角色，一是提供交互环境用于策略训练，二是评估筛选用于策略测试，两种使用方式均需要世界模型对状态转移的推演能力。

综合学术研究与当前产业实践，世界模型的概念逐渐清晰，世界模型必须内化物理世界的演化规律，由三种角色功能实现智能体内部对物理环境因果结构的计算模拟，进而为具身智能的智能水平突破提供必要基础。

# 03 世界模型的技术演进与应用

伴随具身智能产业逐渐成熟，对于数据、仿真等核心需求显著升级，正在推动世界模型从“视觉合成工具”向“物理预测引擎”再向“因果决策系统”演进。

本章沿着物理一致性层级提升的主线，梳理世界模型技术的演进逻辑。从视觉生成起点，跨越几何一致性门槛，不断挑战动力学一致性瓶颈，最终向因果一致性前沿探索。每一次跃迁都建立在前一阶段技术瓶颈的暴露之上，形成清晰的技术递进链条。

## 3.1 从视觉生成到隐空间表征

**（1）以视频生成为起点**

视频生成模型可以看作是世界模型进入产业和公众视野的起点，然而视频生成模型本身并不构成世界模型。

当这些生成式模型被直接用于机器人策略训练时，由于无法建模动作依赖的状态转移（Action-Conditioned State Transition），模型生成的视频序列缺乏动作标签，视频无法作为带监督信号的训练样本供策略网络学习。

基于视频生成的世界模型探索，正在于实现这种动作条件预测。模型将智能体的具体动作作为显式输入，据此推演环境状态的演化。

产业界利用视频生成模型的探索，标志着人工智能产业的边界正从数字空间向物理空间系统性扩展。

**（2）像素空间的效率瓶颈**

依赖动作的状态预测在概念上打通了视频生成模型与世界模型的边界，典型的技术实践是直接在像素空间中进行未来预测，但在工程上生成和预测存在天然的效率瓶颈。

视频预测需要在连续数百帧上维持时空一致性，计算量随分辨率和帧率呈立方级增长。同时，扩散模型通过数百步迭代去噪从随机噪声中逐步恢复清晰画面，其推理计算量远超同等参数规模的语言模型。

如何实现精度与效率的平衡，直接催生了技术演进的第一道门槛。

**（3）隐空间压缩与推演**

2018 年，Schmidhuber 等人以“World Models”为名，提出了一个由 VAE 感知编码器和 RNN 预测器组成的框架。VAE 负责将高维游戏画面压缩为低维隐空间表征，RNN 负责在隐空间中根据当前状态和动作预测下一时刻状态，控制器再根据预测结果选择动作。

然而，Schmidhuber 的框架在隐空间预测后，仍需通过解码器重建像素画面，其训练目标仍包含重建损失，本质上是在隐空间与像素空间之间建立双向映射。LeCun 在 2022 年提出的 JEPA（Joint Embedding Predictive Architecture）架构，则走向了更彻底的非生成式路线。

JEPA 不重建原始观测的像素，而是学习输入的联合嵌入表征（Joint Embedding），直接在抽象的表征空间中预测未来状态的表征。具体而言，JEPA 通过编码器将观测映射为隐空间向量，预测器在隐空间中根据当前状态和动作推演未来隐状态，而无需将预测结果解码回像素空间。

这一架构选择对世界模型具有两重意义。其一，它规避了像素重建的计算开销与信息瓶颈，使预测过程完全在压缩后的隐空间中进行，天然契合实时推演的需求。其二，它将模型的优化目标从“像素级相似”转向“表征级一致”，使隐空间向量可以专门承载物理状态的几何与动力学信息，而非浪费维度去编码对人类观察有用但对物理预测冗余的视觉纹理。

当前，隐空间表征已成为解决效率问题的关键方法，可以概括为以下三个关键步骤：

首先是学习压缩。通过训练一个编码器 - 解码器结构的神经网络，让模型学会将一帧高分辨率图像压缩为一个维度远小于像素数的隐状态向量，再从这个向量中重建出与原图尽可能接近的画面。

然后是隐空间推演。在隐空间中训练一个预测器，根据当前隐状态和候选动作，预测下一时刻的隐状态。

最后，选择性解码。根据下游任务的需要，决定是否将隐状态还原为可视画面。策略训练中对视觉细节要求不高时，隐状态本身就是足够的训练信号。

在实际产业应用中，隐空间表征主要用于提升世界模型的合成器能力，目的是大量生成虚拟的示范轨迹，从而解决机器人真实数据稀缺问题。

通常采用的一种方式是动作条件轨迹生成。先给定一组候选动作，世界模型根据当前观察和任务要求，预测动作发生后的环境变化。这种方式生成的数据是动作与画面的配对，要求预测的画面不仅在视觉上逼真，还要在时间上连贯、物理上可信，并且对后续的决策有用。

另一种方式是逆动态生成。先利用模型生成未来状态的预测序列，可以是完整视觉轨迹、潜在表示或稀疏关键帧，然后再用一个逆动力学模型反向推导出为了达到这些未来状态，机器人应该执行的动作。

这两种方式均可以扩充训练数据，让模型可以在低成本下获得大量预训练或微调所需的示范样本。目前，产业内已出现许多有代表性的世界模型合成器，比如 Genie Envisioner、DreamGen、GigaWorld 等。同时，具身大脑企业也选择将世界模型作为内部预测模块的场景中，星动纪元、跨维智能、自变量科技等企业均有探索，在隐空间中完成状态推演，避免显式视频生成带来的高延迟和高算力消耗。

## 3.2 从几何一致性到动力学一致性

**（1）三维重构与几何一致性**

隐空间表征解决了工程上的效率问题，但无法解决结构问题，无法判断物体是否发生了穿透。

在生成精度和效果方面，三维重构技术提供了相对成熟的解决方案。3D 高斯泼溅和神经辐射场为从多视角二维

图像中重建高质量三维表征提供了成熟方法。3D 高斯泼溅（3D Gaussian Splatting）通过优化大量椭球体的位置、协方差和颜色参数，能够在给定多视角图像后重建出高质量的三维场景表征；神经辐射场（NeRF）及其变体通过隐式函数学习场景的密度和颜色分布，可生成任意新视角下的逼真画面。

这些技术在静态或慢速动态场景中已能提供较高的几何一致性。部分世界模型创业企业所宣称的“3D 重建 + 物理一致性”，本质上是在这一层级上确保模型对物体空间关系的表征不违反几何约束。

然而，几何一致性在动态场景中仍面临挑战。当物体发生快速运动、碰撞或变形时，维持连续的、不穿透的几何表征需要高帧率的状态更新和高精度的几何建模。当前多数 3D 重建技术在帧率、精度和计算开销之间仍存在权衡，尚未达到在复杂动态场景中实时维持几何一致性的水平。

当前发展阶段内，生成的数据在简单、结构化场景中可有效补充真实数据，但在涉及复杂接触、碰撞和变形的任务中，几何误差会迅速累积，导致策略在真实部署中失效。

要突破这一局限，世界模型必须确保状态转移在力学上是正确的，实现动力学一致性。

**（2）动力学一致性的探索**

目前，对世界模型动力学一致性的技术探索沿两条路径展开。

第一条是显式物理引擎嵌入，即将物理定律以可微分方程的形式硬编码进世界模型的架构中，使模型的前向传播本身就遵循力学守恒律。英伟达的 PhysX 可微分版本、Google 的 Brax、松应科技自研的可微分物理引擎中间件均属此类。其优势在于物理定律的硬约束保证了长程推演的稳定性，其劣势在于真实世界的物理参数往往是难以精确测量的，受多种环境因素的影响。这些参数需要从数据中辨识，而辨识过程本身又面临数据稀缺和泛化挑战。

第二条是隐式物理规律学习，即通过海量物理交互数据的训练，让模型在神经网络权重中隐式编码力学规律。前文提及的 JEPA 架构，和 Dreamer 系列是这一路径在学术界的标杆，模型从像素级观测中学习隐空间动力学，在隐空间中推演状态转移，而无需显式嵌入物理方程。其优势在于避免了人为建模的假设局限性，而隐式学习有潜力捕捉那些难以用解析公式表达的复杂物理现象。其劣势同样显著：隐式编码的“物理知识”缺乏保真性保证。模型可能在训练数据分布内表现出合理的行为，但一旦场景参数外推，参数超出训练范围，便可能产生违反守恒律的预测。隐式学习仍与统计相关，无法理解物理关系。

实践中两条路径正在走向融合。部分企业尝试将可微分物理引擎作为世界模型的底层算子，在其上构建可学习的神经网络模块，使模型既能享受物理定律的硬保障，又保留从数据中学习复杂现象的能力。

**（3）从环境构建到环境使用的产业链条**

当满足几何一致性和动力学一致性的基本要求，世界模型开始具备基础功能，正被用于搭建起“环境构建 - 验证 - 使用”的产业链条。

在环境构建环节，一批企业致力于提供高质量的三维几何建模与物理仿真能力，为策略训练搭建接近真实世界的虚拟空间。英伟达的 Omniverse 平台是这一环节的产业标杆，它整合了高精度三维建模与物理仿真引擎，使机器人策略可以在视觉和几何双重维度上接近真实世界的虚拟环境中训练。国内企业中，极佳视界的“4D 世界生成”尝试将静态三维场景扩展为包含时间维度的动态空间，智象未来的“Physics-Aware 3D Generation”则在物体碰撞和自由落体场景中初步验证了动力学一致性。

在环境验证环节，模拟环境的可信度需要独立的测试与审核机制。一个虚拟环境在多大程度上复现了真实物理世界的状态转移规律，需要标准化的工具来度量。光轮智能正是从这一需求切入，它不构建世界模型本身，而是为世界

模型提供物理一致性的测试验证工具链，对模型输出的几何一致性和动力学一致性进行标准化评估。松应科技的可微分物理引擎中间件则定位为“模拟器的操作系统”，为上层世界模型提供可微分的物理仿真环境，使物理约束可以直接嵌入模型的训练和推理管线，从架构层面保障仿真环境的物理可信度。

在环境使用环节，世界模型的应用已在自动驾驶和机器人操作两个领域展开初步探索。Wayve 的 GAIA-1 和特斯拉的 World Model 均被用于在部署前对规控算法的候选轨迹进行虚拟验证，筛选出碰撞风险最低的行驶方案。机器人操作领域，部分具身大脑企业将世界模型用作操作序列的“预演器”，在长序列操作和接触密集型任务中显著提升了任务成功率。

三者之中，当前产业实践最为成熟的是环境构建环节，环境验证尚处于工具链建设阶段，环境使用则高度依赖前两个环节的成熟度。

## 3.3 从状态预测到因果决策

**（1）规划器与因果一致性**

立足当下，即使动力学一致性得到保障，世界模型也仅仅能实现预测状态转移，而非理解因果机制。当环境中出现物体行为偏离预期、或需要反事实推理时，纯粹的动力学预测无法回答解释原因。下一个技术门槛随之出现，世界模型的终极目标是从动力学一致性迈向因果一致性，实现可干预性和反事实推理能力。

世界模型规划器角色的诞生，源于具身智能从“在受控环境中执行预设任务”向“在开放环境中自主决策”的演进需求。在复杂操作场景中，机器人不仅需要在多个候选动作中做出选择，还需要在执行过程中应对意外状况，比如物体没有按预期移动、环境出现未建模的障碍、前序动作的效果与预测不符。在这些情况下，策略不能仅依赖预训练的行为模式，必须实时理解“为什么会发生意外”并据此调整后续动作。

对因果一致性的研究可追溯到 Pearl（2009）的因果阶梯理论。Pearl 将认知世界的能力分为三个递进层级：第一层是关联”，从观测数据中发现变量之间的统计相关性；第二层是“干预”，主动改变某个变量，观察另一个变量是否随之变化；第三层是“反事实推理”，在事件发生后追问假设情境。

实现可干预性与反事实推理是自主规划的能力门槛。既能给定动作 A，正确预测物理后果 B；又能给定预期的物理后果 B，追溯出需要执行的动作 A；以及在反事实场景中做出正确判断。实现这一目标的难度在于，基于统计的结果是一个明确的概率结果，因果推理是基于不同行为的结果预测，存在本质差异。

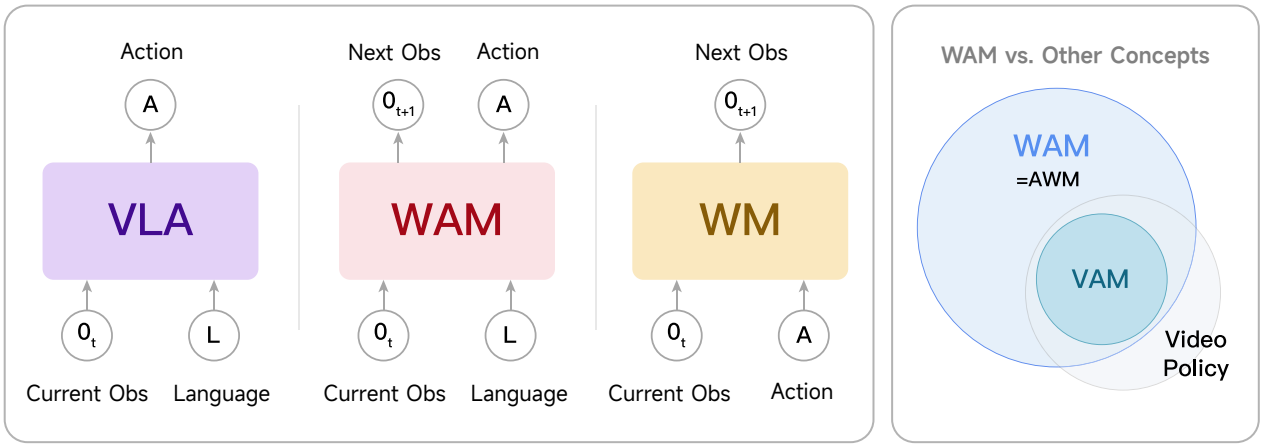
目前，世界模型规划器的最直接应用形态是作为模型预测控制（MPC）的替代方案。传统 MPC 依赖显式的物理模型和在线优化求解器，计算开销大、建模精度受限。基于世界动作模型（World Action Model，WAM）的隐式规划器可以直接从数据中学习“推演 + 决策”的端到端映射，在部分任务上展现出比传统 MPC 更高的计算效率和泛化能力。

更前沿的应用方向是，端到端的自主决策系统。部分具身大脑企业正在探索将 WAM 直接嵌入机器人控制闭环，给定任务目标，模型在内部推演多种可能的动作序列及其物理后果，选择推演结果最优的动作序列执行，并在执行过程中根据实时反馈动态调整推演方向。这种“想象 - 决策 - 验证 - 调整”的闭环，是规划器从实验室走向产业的关键一步。

**（2）规划器角色的产业深化**

当物理世界模型的规划器角色进一步将世界建模与动作生成耦合进单一架构时，便形成了世界动作模型。

WAM 源自 VLA 模型与世界模型的融合。WAM 将环境动力学建模与运动控制相结合，是物理世界模型在具身智能产业中的前沿应用形态，其核心特征在于整合了“预测”和“决策”，不仅预测环境在动作作用下的演化轨迹，还必须在同一框架下协同产出可执行的动作序列。




注：图片来源《World Action Models: The Next Frontier in Embodied AI》

**图 3 世界动作模型及相关概念对比**

在具身智能架构中，世界模型起初主要处于辅助地位，负责预测状态变化，策略模块再根据预测结果选择动作。这种解耦设计的优势在于模块独立、可替换，但其内在局限同样显著，世界模型的预测偏差会不可逆地污染策略决策，而策略的反馈信号却难以反向优化世界模型的预测能力，世界动作模型正是为了解决此问题。

从生成式世界模型到物理世界模型，再到世界动作模型，概念在逐级收紧，功能在逐级增强，但技术落地的难度也在逐级递增。

**（3）世界动作模型的探索**

世界模型在规划器方向的探索已经进入具身智能的应用，世界动作模型（WAM）的架构是主要探索方向。

WAM 将世界建模与动作生成耦合进单一模型，不再将“预测”和“决策”分离为两个独立模块，当前主要有两种架构设计思路。

一种架构是级联式 WAM，采用“先预测状态、后解码动作”的序贯流水线结构。第一阶段由世界模型根据当前观测与任务指令，预测未来的状态序列。这一预测可以在像素空间中进行画面生成，也可以在隐空间中进行状态表征生成。第二阶段由一个独立的动作解码器接收预测出的未来状态，反向推导出可执行的动作序列。这种两阶段设计的优势在于结构灵活，但其内在风险在于误差的级联放大。

一种架构是联合式 WAM，将世界建模与动作生成整合进单一模型，在共享目标函数下联合训练，同步输出未来状态与对应动作。当前主流实现以潜空间为核心载体，将观测 Token 与动作 Token 在潜空间中深度融合，迫使模型主动内化“环境动态”与“控制信号”之间的因果依赖。这种设计从机制上规避了级联式的误差累积问题，同时可以在预训练阶段已习得的物理运动先验，使动作头无需从零学习动态约束。

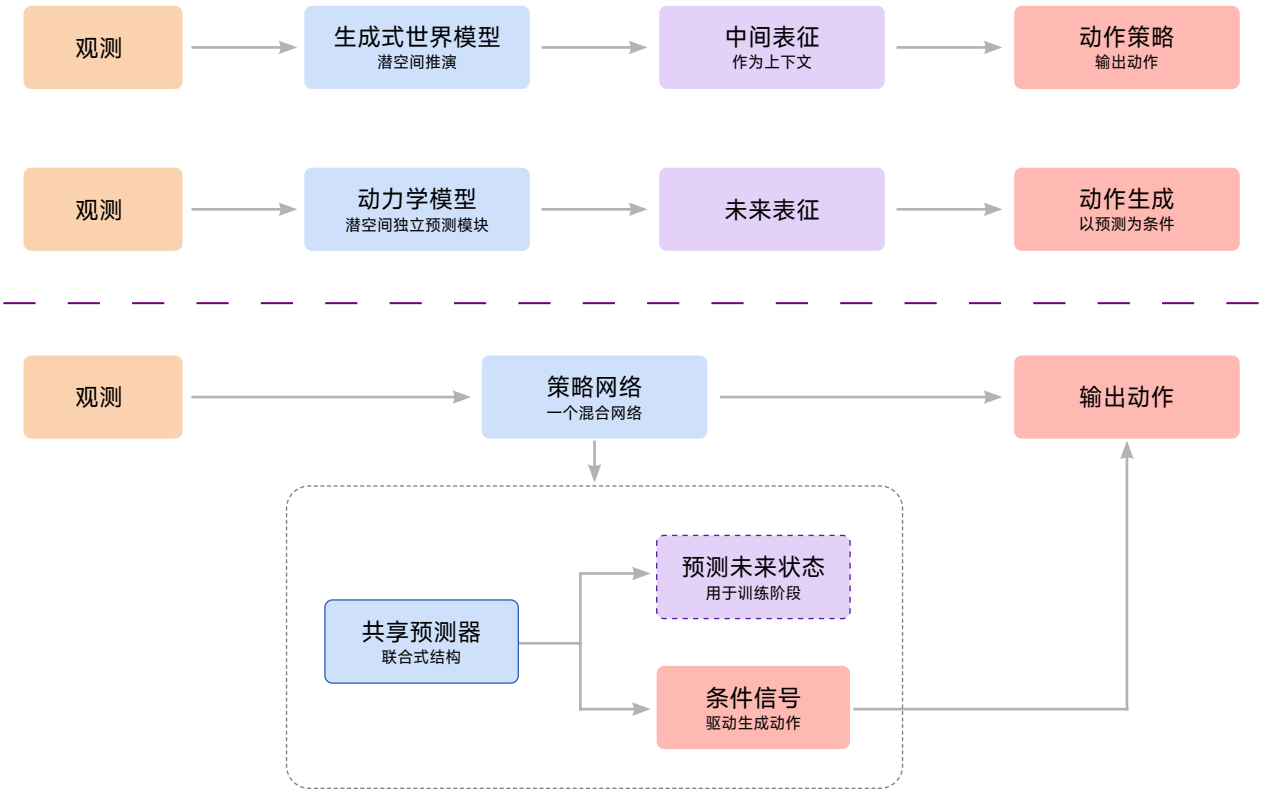



**图 4　世界动作模型技术路线示意**

此外，因果推断机制的嵌入也是一个前沿探索方向。逆矩阵科技在“逆动力学 + 因果推断世界模型”方向上的探索，正试图在架构层面引入因果结构，在统计关联外，学习“因为 A，所以 B”的因果机制，使预测结果具备可干预性和反事实推理能力。拓元智慧的“认知架构 + 世界模型”则从另一个角度切入，将符号化的因果推理规则与神经网络的世界模型结合，试图在保持模型学习能力的同时注入可解释的因果结构。

由于机制更加复杂，WAM 的评估必须同时兼顾世界建模与动作生成两个维度，在“世界建模保真度”与“动作决策精度”之间寻求更可控的权衡。在架构设计上，目前尚无统一框架能在所有任务上同时取得最优。同样，在物理一致性上依然薄弱，未来状态的预测仍会出现物体穿透、漂浮等违反物理规律的现象。此外，长程推演的误差累积也未得到根本解决，预测误差与决策偏差可能形成相互强化的恶性循环。

世界动作模型是世界模型在具身智能领域应用的前沿方向，但当前仍处于早期阶段，距离通用落地存在多重技术瓶颈。

未来发展阶段内，世界模型仍长期面临着两大核心工程挑战，即物理参数辨识和长程预测的误差累积。一个具备动力学一致性的世界模型，其预测精度高度依赖于物理参数的准确性，而真实场景中这些参数往往是未知且时变的。在单步或短程预测中，微小的力学偏差可以被忽略，预测轨迹与真实轨迹之间的误差可以在下一帧的感知反馈中被纠正。但在长程推演中，误差随步数累积呈指数发散。这在自动驾驶和机器人实际操作中存在巨大的潜在风险。

世界模型的每一次角色功能变化，都对应着物理一致性要求的逐级提升和应用场景的逐级拓展。当前产业进展正处于攻克模拟器功能的中后期，动力学一致性的技术路径已初步打通，但尚未形成产业标准，规划器阶段则在学术和产业的交界地带展开探索。世界模型不是一蹴而就的通用基础设施，而是需要在物理一致性的阶梯上长期攀登。

# 04 世界模型与大模型发展对比分析

大语言模型在过去五年间，从技术范式创新开始，参数规模持续扩大，能力随之涌现，商业化路径从 API 调用到订阅服务快速铺开。产业界对人工智能发展逐渐形成共识，默认能力的涌现可以经由规模扩张被触发，商业价值可以在技术尚未完全成熟时即被兑现。

世界模型被寄予多种功能和场景的应用，具有与大模型相似的“通用”可能性，因此，探索一个具备能力涌现、泛化通用的世界模型成为赛道目标。

然而，世界模型与大模型在技术本质、工程路径和价值兑现三个维度上存在结构性差异。这些差异决定了世界模型很难复制大语言模型“规模扩张 - 能力涌现 - 快速商业化”的发展范式。

## 4.1 技术范式差异

世界模型与大模型在技术层面的差异，主要体现在参数规模的需求量级，和模型架构的设计逻辑。

**（1）词元（Token）化与损失函数差异**

语言是人类创造的离散符号系统，分词器将语言切分为有限词表中的离散 Token，每个 Token 对应一个高维嵌入向量。这一过程在语义层面是自然的、无损的。

到了视觉层面，视觉 Token 化是人为构建的近似状态，其信息损失在训练初期即被固化。

但进入物理空间，真实物体都具备连续的几何形状、材质属性、表面摩擦系数和变形特性；物理交互都涉及力、速度、碰撞和能量耗散的多维耦合。物理变量难以被自然地切分为离散的 Token，也难以嵌入一个维度固定的向量空间。

语言模型的训练目标是最小化下一个 Token 的预测交叉熵损失。这一损失函数在数学上等价于最大化训练数据似然，其结果是模型在统计意义上复现训练语料的分布。语言生成的“正确性”由人类主观感受评判，即使事实性有误，也不影响模型在损失函数层面的优化方向。

世界模型的训练目标则必须同时面对多重相互冲突的约束，不同物理层级的损失在优化方向上也并非一致。例如，一个模型可能通过牺牲物理正确性来换取更好的视觉逼真度，而单一的重建损失函数无法区分这种偏差。

**（2）参数规模量级差异**

大语言模型的参数增长轨迹为“规模定律”提供了经验基础。据报道数据从 GPT-2 的 15 亿参数到 GPT-4 的约 1.8 万亿参数，模型在语言理解和生成能力上出现了多次质的跃升，部分能力甚至是未曾被设计过的“涌现”。

大语言模型的 Transformer 架构在数百至数千维的语义向量空间中运作，这个空间的维度是有限的超参数，其承载的语义结构完全由训练语料的统计分布所决定。

相比之下，物理世界的状态空间则几乎是无限的。一个粗略的量级推算，如果语言模型的参数天花板在 TB 级别，那么一个能够支撑通用机器人操作任务的物理世界模型，其参数需求可能在 PB 级别，两者相差三个数量级。

更根本的问题在于，参数规模的扩大是否必然带来物理预测能力的提升，目前没有任何实验证据可以证实或证伪。Scaling Law 在语言模型中是一条已被验证的增长曲线，但在物理世界模型中，它目前仅停留在假设层面。

**（3）模型架构差异**

大语言模型的主流架构已呈现收敛趋势，Decoder-only Transformer 被多家大模型公司采用。世界模型则面临物理定律的硬约束，而 Transformer 架构未曾解决过此类问题，这对模型架构提出了根本性的新要求。

因为结果的验证是开环的，语言模型可以将所有知识编码为神经网络的隐式权重，不需要任何显式的规则系统。但世界模型若仅依赖隐式权重来学习物理规律，便难以保证在所有预测场景中都不违反守恒律。

因此，物理世界模型的架构更可能走向混合路线，比如当前在模型训练中引入可微分物理引擎，提供显式的力学硬约束，与单一 Transformer 架构形成了鲜明对比。

上述技术差异表明，大语言模型所验证的“Transformer 架构 + 规模扩张”路径，不能直接迁移至世界模型。物理状态空间的连续性、损失函数的多目标冲突，以及物理硬约束对模型架构的要求，意味着世界模型需要在 Token 化方式、训练目标设计和架构选择上重新建立技术基础，而非依赖 Scaling Law 在物理空间中的自动延伸。

## 4.2 工程差异：模型从大到小的逆向挑战

**（1）推理过程的实时性差异**

大语言模型的主流部署模式是云端推理，延迟以秒计量。2024 年以来兴起的 Agent Loop 模式，模型反复调用自身、检索外部工具、多步推理后再输出，本质上是主动接纳并放大了这种延迟，以“用时间换能力”的方式拓展应用边界。这种模式之所以可行，是因为文本对话场景对延迟的容忍度相对较高。

具身智能的运行环境则完全不允许这种时间妥协。机器人在抓取运动中的物体时，视觉感知帧率要求至少 30 帧 / 秒，操作预测和控制闭环方面延迟需要小于 20ms，帧率至少 50 帧 / 秒。当前端侧硬件的实际推理能力与这一要求之间存在数量级的差距。

以当前主流的视频生成模型为例，其参数量远小于头部语言模型，但由于扩散模型的生成机制差异，和视觉数据的时空维度，其推理计算量远超同等参数规模的语言模型。

对于包含更多物理信息的世界模型，伴随模型规模增长，这种推理运算消耗只会更大。

**（2）端侧部署的多重约束**

大语言模型的部署遵循“先做大，再蒸馏做小”的路径。蒸馏和量化时，主要损失的是生成文本的多样性和风格细腻度，这些在多数应用场景中是可接受的代价。模型在云端完成复杂推理，端侧只负责轻量级的交互界面。

世界模型的功能化路径则复杂得多，需要经历“先做大，再做小”的过程，但“做小”的代价不可接受。

在模型训练环节，自动驾驶领域的发展经验已验证了，模型需要先做大，才能突破程序规则带来的功能限制，证明了“先做大模型再追求功能化”在单一场景中是可行的方向。但自动驾驶至今尚未实现完全通用，更遑论跨场景泛化。

当前，由于数据瓶颈、模型架构等限制，世界模型规模还未实现大幅增长，恰恰也说明世界模型的规模变大阶段比语言模型漫长得多。

在向端侧部署环节，差异进一步增加。世界模型在压缩部署时，损失的可能是在长程预测中维系物理一致性的精细表征。这些细节在大型模型中是通过参数规模的冗余被隐式保障的，一旦压缩，它们可能被丢弃。比如，一个用于机器人抓取的世界模型，其隐式编码的接触力分布细节可能在量化过程中被四舍五入，导致策略在真实接触时产生滑脱或过度挤压。

世界模型的“做小”面临多重约束的叠加，具身智能产品需要推理快、功能准、功耗低三者的平衡，端侧芯片的算力上限、电池续航约束、散热条件，共同构成了一个比云端部署严苛得多的工程环境。未来世界模型若实现规模增长，工程部署将成为巨大挑战。

综上，工程约束意味着，世界模型的部署逻辑与大模型存在方向性分歧。大模型通过云端集中推理和端侧轻量分发实现规模化应用，而世界模型若采用同等的压缩与蒸馏策略，可能在长程物理预测中丢失关键细节，直接导致策略在真实环境中失效。这决定了世界模型的工程化重点，不是训练一个通用超大模型再向下适配，而是针对特定物理场景和端侧算力条件，发展可实时运行且物理保真的专用模型。

## 4.3 价值兑现差异：世界模型价值依赖下游载体爆发

大语言模型的商业化路径是直接的。GPT-3 在 2020 年发布后，OpenAI 通过 API 向开发者提供模型调用服务，企业用户按 Token 付费，收入模式清晰且可预测。ChatGPT 在 2022 年底的爆发进一步验证了“模型即产品”的可行性，应用触达数亿 C 端用户，产生了规模化收入的渠道。大语言模型天然位于应用层，其能力可以直接封装为面向终端用户的产品或服务，价值兑现链路极短。

世界模型则处于完全不同的产业链位势，是供下游具身载体调用的基础设施。类似于操作系统之于手机应用、物理引擎之于游戏，世界模型训练完成后，自身并不能直接产生商业价值。它的价值至少经由三个传导环节才能被兑现，首先世界模型本身的技术可用或成熟，下游具身载体实现大规模量产，载体在具体应用场景中产生的经济价值。这其中的每一环都充满不确定性，且传导周期远长于纯软件产品的价值兑现周期。

其中关键是，世界模型的价值兑现需要下游载体的规模爆发，而载体的规模爆发本身又受制于硬件成本、场景需求和基础设施配套等多重因素。当前人形机器人产业仍处于“万台交付”的量级，在载体尚未大规模渗透之前，上游世界模型的技术能力无论多强，都缺乏将其转化为商业收入的出口。

物理世界的摩擦力决定了世界模型的产业节奏天然慢于纯数字智能，且这一差距不会因为资本投入的增加而被线性压缩。世界模型短期内难以通过直接面向终端用户产生爆发式收入增长，更适合作为基础设施类技术的探索和培育。

从产业链位势差异中表明，世界模型短期内难以复制大模型“模型即产品”的变现路径。在下游载体出货量跨越规模化门槛之前，独立的世界模型缺乏直接面向终端市场的商业接口，也难以建立按调用量计费的标准化收入模式。这意味着当前阶段世界模型更适合作为具身智能产业链的使能技术进行长期培育，其投资回报周期应与载体产业的成熟节奏相匹配，而非遵循纯软件产品的快速变现逻辑。

# 05 结论与趋势分析

> 当前，世界模型正处于投资热潮中，对其未来发展的判断逻辑，在相当程度上受到大语言模型的发展经验影响。然而，前文的技术演进分析与范式对比表明，世界模型与大语言模型之间存在本质性的结构差异，前者并非后者的物理空间延伸，而是一个需要独立技术路径和产业逻辑的崭新物种，这将是一个全新的庞大工程系统。

## 5.1 世界模型正在从“生成式 Scaling”到“JEPA 式结构创新”

当前，具身智能产业界刚开始步入“大模型”阶段，对世界模型的主流实践仍延续着生成式模型的技术惯性。但物理世界和语言语义的参数需求不在同一数量范畴，且规模定律在物理模型领域的适用性尚无任何实验证据支撑。

世界模型的能力成长需要逐级跨越，每一级跃迁都需要新的架构设计、新的训练范式和新的验证标准，而非仅仅增加参数规模即可自动跨越。JEPA 所代表的非生成式路线，提供了另一种可能。在抽象隐空间中学习联合嵌入表征并预测未来状态的表征，这一架构选择使预测过程脱离了像素生成的计算负担，同时让隐空间向量专门承载几何与动力学信息，国内已有企业沿类似路线展开探索。

本文认为，世界模型的技术突破不会来自对视频生成模型的简单规模放大，更可能来自于以 JEPA 为代表的结构创新。世界模型的核心指标是对物理状态的保真与推理效率，直接影响了技术突破的路径，从“生成式预测”向“表征式预测”的范式转移正在加速。

## 5.2 世界模型将形成混合架构、功能分层的复杂系统

世界模型在实践中已分化为合成器、模拟器、规划器三种功能角色，但单一架构难以同时满足物理一致性的三重约束。纯神经网络在视觉生成上表现优异，但无法保证力学守恒；传统物理引擎在长程稳定性上具有优势，却难以处理复杂接触与形变；符号因果推理可解释性强，但难以从原始感知数据中自动习得。

这决定了世界模型将走向混合架构与功能分层的系统形态。在底层，可微分物理引擎将扮演“操作系统”的角色，提供标准化的力学约束与几何仿真接口；在中间层，神经网络负责从数据中学习难以解析建模的复杂现象，利用隐空间进行状态推演；在应用层，针对不同任务（合成数据、策略训练、实时决策）将分化出专用模型。

我们期待世界模型成为类似大模型的“通用能力基座”，但这样一个复杂庞大的系统工程已经超越了一家公司的能力、资源范畴，是整个行业的终极目标，也意味着世界模型的收敛将显著慢于大语言模型。未来，世界模型的产业壁垒，将不仅取决于单一模型的能力，更取决于混合架构中各层之间的协同效率与物理一致性保障。

## 5.3 物理世界的现实摩擦力将延缓产业应用节奏

大语言模型的产业飞轮，完全在数字空间完成，服务闭环完全在云端运行，边际成本趋近于零，传播速度极快。全球数十亿互联网用户构成了天然的增量市场，模型能力的每一次提升都可以迅速转化为用户规模的增长和商业收入的扩大。

世界模型的产业飞轮则每一圈都必须经由物理世界。每一次数据闭环都需要真机运行、场景重置、物理交互与人工监督，每一次模型验证都需要在真实或高保真虚拟环境中进行力学校验。这种物理世界的现实摩擦力，不是单纯的技术不成熟问题，而是具身智能固有的成本结构问题。

物理世界的摩擦力，决定了世界模型的产业节奏天然慢于纯数字智能，且这一差距不会因为资本投入的增加而被线性压缩。以自动驾驶的产业经验为参照，从 2004 年 DARPA 挑战赛到 2024 年 Robotaxi 初步商业化，用了整整二十年。世界模型若以通用具身智能为目标，其产业成熟周期至少应以十年为基本单位来计量。

链条越长，预期与现实之间的偏差就越大。在价值兑现路径上，大语言模型是直接面向 C 端或 B 端的应用产品，能力提升与收入增长之间几乎是实时映射。世界模型则是上游基础设施，其技术能力的提升必须先转化为下游载体产品竞争力的增强，再由载体在终端市场的渗透转化为世界模型自身可捕获的经济价值。

## 5.4 下游载体进入商业化与纵向整合趋势

世界模型作为上游基础设施，其价值兑现必须经由“模型 - 载体 - 场景”的三级传导。在下游载体出货量尚未跨越规模化门槛之前，独立的世界模型企业缺乏直接面向终端市场的商业接口，难以建立可持续的营收模式。

这一产业链位势决定了，世界模型企业无法复制大模型“模型即产品”的独立商业化路径。

更现实的产业形态是纵向整合。在大语言模型领域，谷歌、微软等云厂商并未单纯依赖第三方模型供应商，而是自研大模型并将其深度集成进自身产品生态。世界模型领域未来也将呈现出类似的迹象，下游载体企业（如特斯拉、国内头部人形机器人企业）凭借数据采集硬件与产品变现出口的优势，开始自建或深度绑定世界模型团队；上游模型企业则必须通过战略联盟、合资或并购方式，与载体企业形成“数据 - 模型 - 产品”闭环。纯粹的模型供应商将面临“技术有壁垒、商业无出口”的困境，这一趋势将对独立的世界模型创业企业构成生存压力。

本文认为，未来 3-5 年内，世界模型赛道难以出现独立的平台型巨头，而是会形成若干“载体 - 模型联合体”，其内部实现需求定义、数据供给与价值兑现的闭环。

## 5.5 从百家争鸣到聚焦，收敛周期将显著长于大模型

世界模型赛道当前处于产业早期的“百家争鸣”阶段，多种技术路线并行发展，资本和政策资源在方向上高度分散。这些路线并非简单的替代关系，而是对应物理一致性不同层级的技术攻关。这意味着，世界模型的市场出清不会由融资规模或参数竞赛驱动，而将由物理一致性的可验证性驱动。

当技术路线经历一段时间的并行探索后，部分方向会因为技术瓶颈无法突破、应用场景无法闭环或竞争格局恶化而自然淘汰。资源将随之向那些已被初步验证的技术路线和团队集中。

当前，WorldArena、WorldScore 等评测体系已开始对世界模型的几何一致性和动力学一致性进行标准化评估。随着这些评测体系的成熟，仅具视频生成能力却声称具备物理预测能力的模型将被市场淘汰。能够同时通过几何一致性、动力学一致性和部分场景因果一致性测试的模型，将获得资源聚集效应。

本文预判，这一收敛过程需要 5-8 年，且不会是全局性的“一家独大”，而是场景级的局部收敛。自动驾驶、仓储物流、工业装配等对物理一致性要求明确、评测标准易建立的垂直场景，将率先完成资源整合与格局固化；通用家庭服务机器人等开放场景，其世界模型的成熟周期将更为漫长。在每一个率先收敛的垂直场景中，率先实现“数据闭环 + 载体部署 + 商业变现”的企业联盟，将形成难以逾越的生态壁垒。



# 国际先进技术应用推进中心（深圳）

## 为技术对接场景，为企业对接技术

**研究中心介绍**

国际先进技术应用推进中心（深圳），简称国先中心，是在国家发展改革委、深圳市政府支持指导下设立，深圳市科技创新局作为业务主管部门，聚焦人工智能、具身智能、低空经济等重点领域，依托粤港澳大湾区数字经济研究院建设的具有技术先进性、平台开放性、资源国际化、运作市场化、服务专业化的世界级先进技术应用推广平台。


**国际先进技术应用推进中心（深圳）**

深圳市福田区红柳道 1 号

电话：0755-83212983

邮箱：gxzx@idea.edu.cn

www.idea.edu.cn